



Regularização de um problema inverso linear

Prof. André L. A. dos Reis

Rio de Janeiro 2022

Objetivos da aula

- * Os problemas mal postos
- * O problema visto de uma perspectiva matemática
- * Regularização de Tikhonov de Ordem Zero e de Ordem Um
- * Exemplo:
 - A Camada equivalente

Os problemas mal postos

O que procuramos na inversão é um **conjunto de parâmetros** que minimize a distância entre o **vetor de dados observados** e o **vetor de dados preditos** pelo modelo.

Matematicamente, este é um processo de otimização no qual queremos **minimizar a norma euclidiana** de uma função que mede a distância entre **os dois vetores**!

Matematicamente, este é um processo de otimização no qual queremos **minimizar a norma euclidiana** de uma função que mede a distância entre **os dois vetores**!

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

Quando falamos em minimizar uma função, significa que queremos tomar o gradiente desta função e igualarmos a zero.

Uma vez que esta função é minimizada...

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\dagger = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados

$$\mathbf{G} = \begin{bmatrix} g_{11} & \dots & g_{1M} \\ \vdots & \ddots & \vdots \\ g_{N1} & \dots & g_{NM} \end{bmatrix}$$

Matriz de sensibilidade: Mede a sensibilidade do i-ésimo dado em relação ao j-ésimo parâmetro

$$g_{ij} = \frac{\partial f_i(\mathbf{p})}{\partial p_j}$$

Devido a própria natureza do **problema inverso**, os **dados geofísicos não são capazes** para descrever os fenômenos que queremos estudar.



Devido a própria natureza do **problema inverso**, os **dados geofísicos não são capazes** para descrever os fenômenos que queremos estudar.

Por este motivo, dizemos que o **problema é mal-posto**. Ou seja, ele sofre com: **falta de unicidade, instabilidade ou inexistência da solução**.


Falta de unicidade: a existência de diversos conjuntos de parâmetros que ajustam um mesmo conjunto de dados.

Falta de unicidade: a existência de diversos conjuntos de parâmetros que ajustam um mesmo conjunto de dados.



Instabilidade: pequenas perturbações nos dados geram diferentes soluções (conjuntos de parâmetros) para o problema inverso.



g_z (mGal)



metros



z


Sob uma perspectiva
matemática...

Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^0$$

Sistemas lineares (caso linear)


$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^0$$

$$\mathbf{A} \mathbf{p} = \mathbf{t}$$


Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^0$$

$$\mathbf{A} \mathbf{p} = \mathbf{t}$$



Sistemas lineares (caso linear)

$$(G^T G) p^\# = G^T d^0$$

O **vetor em vermelho** é
combinação linear dos **vetores**
em verde

$$Ap = t$$

$$p_1 a_1 + p_2 a_2 + p_3 a_3 + p_4 a_4 + p_5 a_5 = t$$

Sistemas lineares (caso linear)

$$(G^T G) p^\# = G^T d^0$$

O **vetor em vermelho** é
combinação linear dos **vetores
em verde**

$$Ap = t$$

A **dependência linear** entre os **vetores
em verde** nos dá uma pista do
condicionamento deste sistema linear

$$p_1 a_1 + p_2 a_2 + p_3 a_3 + p_4 a_4 + p_5 a_5 = t$$

Sistemas lineares (caso linear)

Exemplo em 2D

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$


Sistemas lineares (caso linear)

Exemplo em 2D

?

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$


$\phantom{\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}}$



Sistemas lineares (caso linear)

Exemplo em 2D

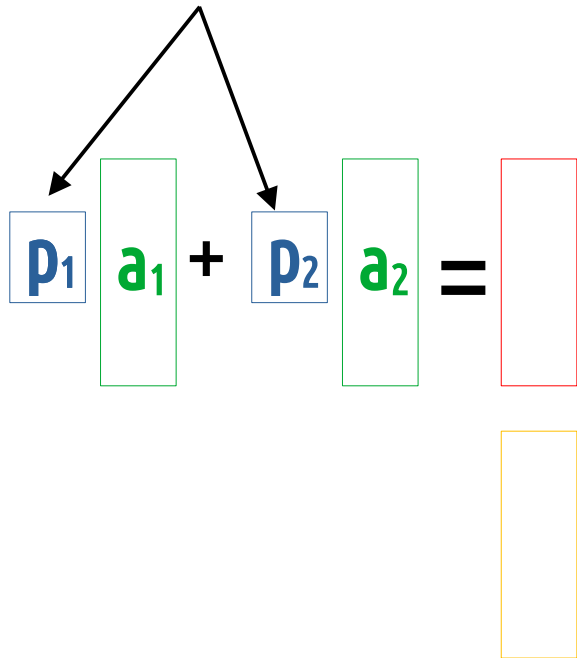
$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$



Sistemas lineares (caso linear)

Exemplo em 2D


Existe somente uma única combinação de p_1 e p_2 que nos fazer reproduzir o **vetor em vermelho**



A diagram illustrating the linear combination of two vectors a_1 and a_2 to produce a red vector. The equation is shown as $p_1 a_1 + p_2 a_2 =$ followed by a red box. Below the red box is a yellow box. Arrows point from the text above to the p_1 and p_2 boxes.

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$

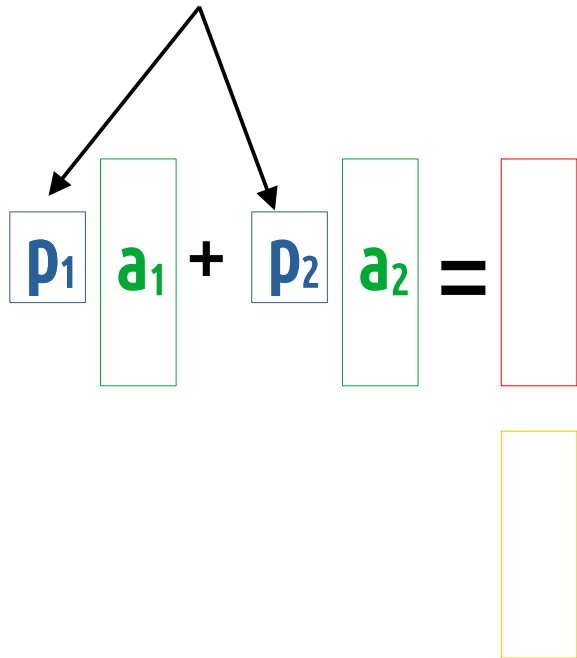
$\phantom{\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}}$




Sistemas lineares (caso linear)

Exemplo em 2D

Existe somente uma única combinação de p_1 e p_2 que nos fazer reproduzir o **vetor em vermelho**

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$



The diagram illustrates the equation $p_1 a_1 + p_2 a_2 = \text{red vector}$. The coefficients p_1 and p_2 are in blue boxes. The vectors a_1 and a_2 are in green boxes. The result is a red box. Below the red box is an empty yellow box. Arrows point from the text above to the p_1 and p_2 boxes.



Sistemas lineares (caso linear)

Exemplo em 2D

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.


$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Neste caso diz-se que o sistema linear é mal-condicionado

Sistemas lineares (caso linear)

Exemplo em 2D



$$\mathbf{A} \mathbf{p} = \mathbf{t}$$



Neste caso diz-se que o sistema linear é mal-condicionado

Regularização de Tikhonov (Ordem Zero e Ordem Um)

A regularização tem como objetivo tornar bem condicionadas as matrizes envolvidas nas soluções dos problemas lineares e não lineares

Matematicamente, o que queremos é minimizar uma função tal como:

$$\Phi(\mathbf{p}) = \psi(\mathbf{p}) + \mu\theta(\mathbf{p})$$

Função Objetivo

O primeiro termo é a **função de ajuste** e o segundo termo é a **função regularizadora**. O **parâmetro de regularização** é dado por μ .

Regularização de Tikhonov de Ordem Zero (ou Norma Mínima)

$$\Phi(\mathbf{p}) = \psi(\mathbf{p}) + \mu \theta(\mathbf{p})$$

Função Objetivo

$$\theta(\mathbf{p}) = \mathbf{p}^T \mathbf{p}$$

Função regularizadora

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{I}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^0$$

Estimador de mínimos quadrados regularizado
(Norma mínima)

Regularização de Tikhonov de Ordem Um (ou Suavidade)

$$\Phi(\mathbf{p}) = \psi(\mathbf{p}) + \mu \theta(\mathbf{p})$$

Função Objetivo

$$\theta(\mathbf{p}) = \mathbf{p}^T \mathbf{R}^T \mathbf{R} \mathbf{p}$$

Função regularizadora


$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{R}^T \mathbf{R}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados regularizado
(Suavidade)


Exemplo

A Camada equivalente


De acordo com a Teoria do Potencial, conseguimos recuperar o efeito gerado por uma distribuição de propriedade física 3D com uma distribuição 2D




Fonte magnética 3D



Camada equivalente



Fonte magnética 3D




Recuperar o efeito de uma fonte 3D assumindo uma distribuição 2D de propriedade física


$$\Delta \mathbf{T}^o = \begin{bmatrix} \Delta T^1 \\ \vdots \\ \Delta T^N \end{bmatrix}$$

Vetor de dados observados


Camada equivalente




Camada equivalente



Camada equivalente




Camada equivalente




A anomalia de campo total predita no i -ésimo ponto de observação gerada por uma fonte esférica com volume v é dada por:

$$\Delta T_i^p = C_m \mathbf{F}_0^T \mathbf{M}_{ij} \hat{\mathbf{m}} p_j$$



Esferas de volume unitário,
que associamos uma direção de
magnetização para cada uma

Camada equivalente



A anomalia de campo total predita no i -ésimo ponto de observação gerada por uma fonte esférica com volume v é dada por:

$$\Delta T_i^p = C_m \mathbf{F}_0^T \mathbf{M}_{ij} \hat{\mathbf{m}} p_j$$

Esferas de volume unitário, que associamos uma direção de magnetização para cada uma

$$\mathbf{M}_{ij} = \begin{bmatrix} \partial_{xx}(1/r_{ij}) & \partial_{xy}(1/r_{ij}) & \partial_{xz}(1/r_{ij}) \\ \partial_{yx}(1/r_{ij}) & \partial_{yy}(1/r_{ij}) & \partial_{yz}(1/r_{ij}) \\ \partial_{zx}(1/r_{ij}) & \partial_{zy}(1/r_{ij}) & \partial_{zz}(1/r_{ij}) \end{bmatrix}$$

Hessiana


$$\mathbf{F}_0 = \begin{bmatrix} \cos I_0 \sin D_0 \\ \cos I_0 \cos D_0 \\ \sin I_0 \end{bmatrix}$$

Campo principal

$$r_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_c)^2}$$

Distância entre o i -ésimo ponto e o centro da esfera

Camada equivalente



A anomalia de campo total predita no i-ésimo ponto de observação gerada por uma fonte esférica com volume v é dada por:

$$\Delta T_i^p = C_m \mathbf{F}_0^T \mathbf{M}_{ij} \hat{\mathbf{m}} p_j$$

Esferas de volume unitário, que associamos uma direção de magnetização para cada uma

$$\mathbf{M}_{ij} = \begin{bmatrix} \partial_{xx}(1/r_{ij}) & \partial_{xy}(1/r_{ij}) & \partial_{xz}(1/r_{ij}) \\ \partial_{yx}(1/r_{ij}) & \partial_{yy}(1/r_{ij}) & \partial_{yz}(1/r_{ij}) \\ \partial_{zx}(1/r_{ij}) & \partial_{zy}(1/r_{ij}) & \partial_{zz}(1/r_{ij}) \end{bmatrix}$$

Hessiana


$$r_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_c)^2}$$

Distância entre o i-ésimo ponto e o centro da esfera

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix} \text{ Vetor de parâmetros}$$


$$\mathbf{F}_0 = \begin{bmatrix} \cos I_0 \sin D_0 \\ \cos I_0 \cos D_0 \\ \sin I_0 \end{bmatrix} \text{ Campo principal}$$

Fonte magnética 3D




Queremos estimar uma **distribuição de momentos** que minimize a distância entre os **dados observados** e os **dados preditos** gerados pela esfera!

Camada equivalente



Fonte magnética 3D




Queremos estimar uma **distribuição de momentos** que minimize a distância entre os **dados observados** e os **dados preditos** gerados pela esfera!


$$\Phi(p) = \psi(p) + \mu\theta(p)$$

Função objetivo

Camada equivalente



Fonte magnética 3D



Queremos estimar uma **distribuição de momentos** que minimize a distância entre os **dados observados** e os **dados preditos** gerados pela esfera!


$$\Phi(p) = \psi(p) + \mu\theta(p)$$

Função objetivo


$$(G^T G + \mu I) p^\# = G^T \Delta T^o$$

Estimador de mínimos quadrados regularizado (Norma mínima)

Camada equivalente



Fonte magnética 3D



Queremos estimar uma **distribuição de momentos** que minimize a distância entre os **dados observados** e os **dados preditos** gerados pela esfera!

$$\Phi(\mathbf{p}) = \psi(\mathbf{p}) + \mu\theta(\mathbf{p})$$

Função objetivo


$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{I}) \mathbf{p}^\# = \mathbf{G}^T \Delta \mathbf{T}^0$$

Estimador de mínimos quadrados regularizado (Norma mínima)

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{R}^T \mathbf{R}) \mathbf{p}^\# = \mathbf{G}^T \Delta \mathbf{T}^0$$

Estimador de mínimos quadrados regularizado (Suavidade)

Camada equivalente



Objetivos da aula

- * Os problemas mal postos
- * O problema visto de uma perspectiva matemática
- * Regularização de Tikhonov de Ordem Zero e de Ordem Um
- * Exemplo:
 - A Camada equivalente

Até breve!