



Regularização de um problema inverso linear

Prof. André L. A. dos Reis

Rio de Janeiro 2023

Objetivos da aula

- * Os problemas mal postos
- * O problema visto de uma perspectiva matemática
- * Regularização de Tikhonov de Ordem Zero e de Ordem Um
- * Exemplo:
 - A Camada equivalente

Os problemas malpostos

O que procuramos na inversão é um **conjunto de parâmetros** que minimize a distância entre o **vetor de dados observados** e o **vetor de dados preditos** pelo modelo.

Matematicamente, este é um processo de otimização no qual queremos **minimizar a norma euclidiana** de uma função que mede a distância entre **os dois vetores**!

Formulação matemática

Matematicamente, este é um processo de otimização no qual queremos **minimizar a norma euclidiana** de uma função que mede a distância entre **os dois vetores!**

$$\varphi(\mathbf{p}) = \| \mathbf{d}^o - \mathbf{d}^p \|_2$$

Função de ajuste

$$\nabla \varphi(\mathbf{p}) = \mathbf{0}$$

Quando falamos em minimizar uma função, significa que queremos tomar o gradiente desta função e igualarmos a zero.

Formulação matemática

Uma vez que esta função é minimizada...

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados

Matriz de sensibilidade: Mede a sensibilidade do i-ésimo dado em relação ao j-ésimo parâmetro.

$$\mathbf{G} = \begin{bmatrix} g_{11} & \cdots & g_{1m} \\ \vdots & \ddots & \vdots \\ g_{n1} & \cdots & g_{nm} \end{bmatrix} \longrightarrow g_{ij} = \frac{\partial f_i(\mathbf{p})}{\partial p_j}$$

Devido a própria natureza do **problema inverso**, os **dados geofísicos não são capazes** para descrever os fenômenos que queremos estudar.

Por este motivo, dizemos que o **problema é malposto**. Ou seja, ele sofre com: **falta de unicidade, instabilidade** ou **inexistência da solução**.


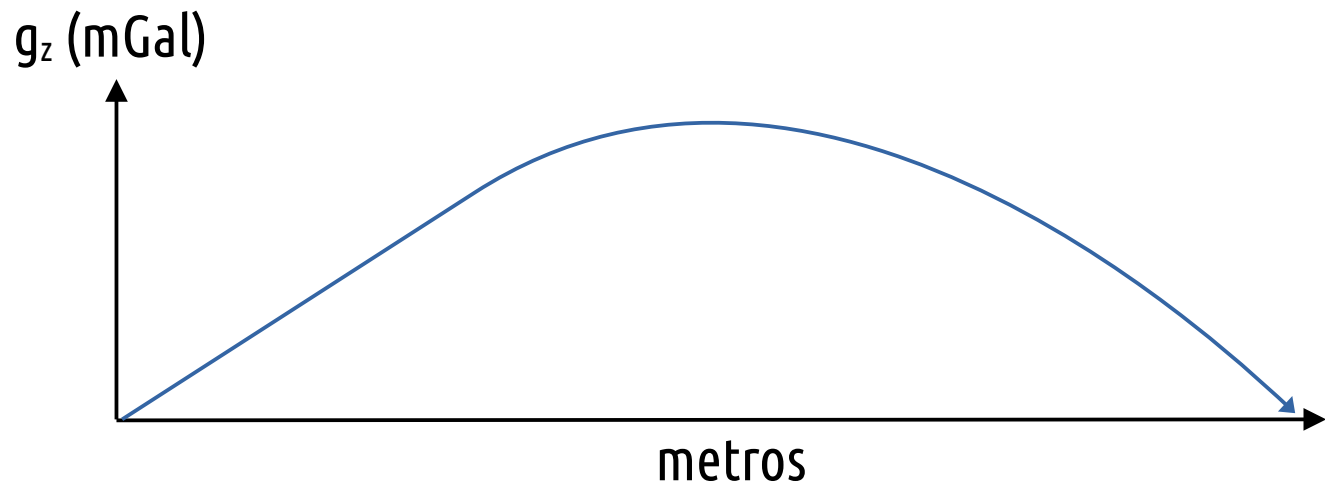
Existência : quando o problema inverso não admite alguma solução exata para a descrição dos dados observados.

Unicidade : a existência de diversos conjuntos de parâmetros que ajustam um mesmo conjunto de dados.


Instabilidade : pequenas perturbações nos dados geram diferentes soluções (conjuntos de parâmetros) para o problema inverso.

Problema malposto


Combinações de diferentes
geometrias e/ou
distribuições de densidade
ajustam um mesmo conjunto
de dados



Problema malposto



Combinações de diferentes
geometrias e/ou
distribuições de densidade
ajustam um mesmo conjunto
de dados



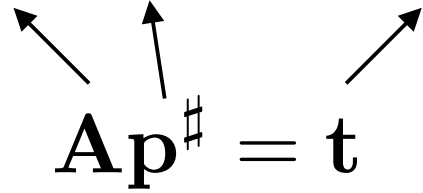
O problema de um ponto de vista matemático

Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

Sistemas lineares (caso linear)


$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

$$\mathbf{A} \mathbf{p}^\# = \mathbf{t}$$


Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

$$\mathbf{A} \mathbf{p}^\# = \mathbf{t}$$



Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

O **vetor em vermelho** é
combinação linear dos **vetores**
em verde

$$\mathbf{A} \mathbf{p}^\# = \mathbf{t}$$

$$\boxed{p_1} \mathbf{a}_1 + \boxed{p_2} \mathbf{a}_2 + \boxed{p_3} \mathbf{a}_3 + \boxed{p_4} \mathbf{a}_4 + \boxed{p_5} \mathbf{a}_5 = \mathbf{t}$$

Sistemas lineares (caso linear)

$$(\mathbf{G}^T \mathbf{G}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

O **vetor em vermelho** é
combinação linear dos **vetores
em verde**

$$\mathbf{A} \mathbf{p}^\# = \mathbf{t}$$

A **dependência linear** entre os **vetores
em verde** nos dá uma pista do
condicionamento deste sistema linear

$$\begin{bmatrix} \mathbf{p}_1 \\ \mathbf{a}_1 \end{bmatrix} + \begin{bmatrix} \mathbf{p}_2 \\ \mathbf{a}_2 \end{bmatrix} + \begin{bmatrix} \mathbf{p}_3 \\ \mathbf{a}_3 \end{bmatrix} + \begin{bmatrix} \mathbf{p}_4 \\ \mathbf{a}_4 \end{bmatrix} + \begin{bmatrix} \mathbf{p}_5 \\ \mathbf{a}_5 \end{bmatrix} = \begin{bmatrix} \mathbf{t} \end{bmatrix}$$

Sistemas lineares (caso linear)

Exemplo em 2D

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$


Sistemas lineares (caso linear)

Exemplo em 2D

?

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$


$\phantom{\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}}$



Sistemas lineares (caso linear)

Exemplo em 2D

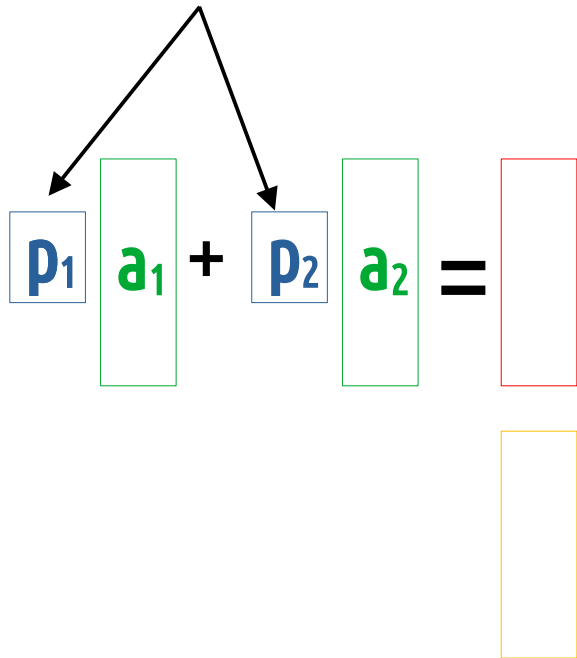
$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$



Sistemas lineares (caso linear)


Exemplo em 2D

Existe somente uma única combinação de p_1 e p_2 que nos fazer reproduzir o **vetor em vermelho**



A diagram illustrating the linear combination of two vectors a_1 and a_2 to produce a red vector. The equation is shown as $p_1 a_1 + p_2 a_2 =$ followed by a red rectangular box. Below this, there is a yellow rectangular box. Arrows point from the text above to the p_1 and p_2 terms in the equation.

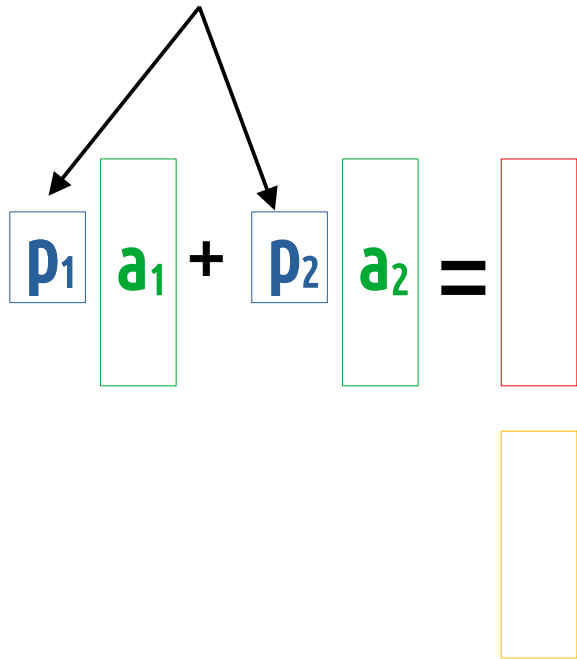
$$p_1 a_1 + p_2 a_2 =$$




Sistemas lineares (caso linear)

Exemplo em 2D

Existe somente uma única combinação de p_1 e p_2 que nos fazer reproduzir o **vetor em vermelho**

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$



The diagram illustrates the equation $p_1 a_1 + p_2 a_2 = \text{red vector}$. The coefficients p_1 and p_2 are in blue boxes. The vectors a_1 and a_2 are in green boxes. The result is a red box. Below the red box is a yellow box, which represents the vector a_1 from the adjacent graph.



Sistemas lineares (caso linear)

Exemplo em 2D

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{} \\ \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.

$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Sistemas lineares (caso linear)

Exemplo em 2D

Perceba que nessa situação existem diversas combinações de p_1 e p_2 que reproduzem o **vetor em vermelho**.


$$\boxed{p_1} \boxed{a_1} + \boxed{p_2} \boxed{a_2} = \boxed{}$$




Neste caso diz-se que o sistema linear é mal condicionado

Sistemas lineares (caso linear)

Exemplo em 2D



$$\mathbf{A} \mathbf{p} = \mathbf{t}$$



Neste caso diz-se que o sistema linear é mal condicionado

Regularização de Tikhonov

(Ordem Zero e Ordem Um)

A regularização tem como objetivo tornar bem condicionadas as matrizes envolvidas nas soluções de problemas lineares e não lineares

Matematicamente, o que queremos é minimizar uma função tal como:

$$\Gamma(\mathbf{p}) = \varphi(\mathbf{p}) + \mu\theta(\mathbf{p})$$

Função Objetivo

O primeiro termo é a **função de ajuste** e o segundo termo é a **função regularizadora**. O **parâmetro de regularização** é dado por μ .

Regularização de Tikhonov de Ordem Zero (ou Norma Mínima)

$$\Gamma(\mathbf{p}) = \varphi(\mathbf{p}) + \mu\theta(\mathbf{p})$$

Função Objetivo

$$\theta(\mathbf{p}) = \mathbf{p}^T \mathbf{p}$$

Função regularizadora

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{I}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados regularizado
(Norma mínima)

Regularização de Tikhonov de Ordem Um (ou Suavidade)

$$\Gamma(\mathbf{p}) = \varphi(\mathbf{p}) + \mu\theta(\mathbf{p})$$

Função Objetivo

$$\theta(\mathbf{p}) = \mathbf{p}^T \mathbf{R}^T \mathbf{R} \mathbf{p}$$

Função regularizadora

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{R}^T \mathbf{R}) \mathbf{p}^\# = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados regularizado
(Suavidade)

Exemplo

A Camada equivalente


De acordo com a Teoria do Potencial é possível **recuperar o efeito gerado por uma distribuição tridimensional de propriedade física por uma distribuição bidimensional.**

Em geral, esta técnica serve para **processamentos de dados potenciais** (dados de gravidade ou magnéticos), como também, mais recentemente, **interpretação dos corpos em subsuperfície.**

Camada equivalente

$$|\mathbf{r} - \mathbf{r}''| = \sqrt{(x - x'')^2 + (y - y'')^2 + (z - z_c)^2}$$

Uma camada contínua e infinita




As componentes do campo são dadas por:

$$B_\alpha^\dagger(\mathbf{r}) = \gamma_m \int_{-\infty}^{+\infty} \int_{-\infty}^{+\infty} p(\mathbf{r}'') \hat{\mathbf{u}}(I, D) \cdot \partial_\alpha \nabla \frac{1}{\|\mathbf{r} - \mathbf{r}''\|_2} dS''$$

Camada equivalente

$$|\mathbf{r} - \mathbf{r}''| = \sqrt{(x - x'')^2 + (y - y'')^2 + (z - z_c)^2}$$

Uma camada **contínua e infinita**




A anomalia de campo total é dada por:

$$\Delta T^\dagger(\mathbf{r}) = \hat{\mathbf{u}}(I_0, D_0) \cdot \mathbf{B}^\dagger(\mathbf{r})$$

O problema geofísico

Fonte magnética 3D




Recuperar o efeito de uma fonte 3D por uma **camada plana** abaixo da superfície de observação

$$\Delta \mathbf{T}^o = \begin{bmatrix} \Delta T_1 \\ \vdots \\ \Delta T_n \end{bmatrix}$$

Vetor de dados observados


Camada equivalente



Modelagem direta

A **anomalia de campo total predita** no i-ésimo ponto de observação gerada por uma **fonte equivalente** é dada por:

$$\Delta T_i^p = \gamma_m \hat{\mathbf{F}}_0^T \mathbf{M}_{ij} \mathbf{m} p_j$$



$$\mathbf{M}_{ij} = \begin{bmatrix} \frac{\partial_{xx}}{l_{ij}} & \frac{\partial_{xy}}{l_{ij}} & \frac{\partial_{xz}}{l_{ij}} \\ \frac{\partial_{yx}}{l_{ij}} & \frac{\partial_{yy}}{l_{ij}} & \frac{\partial_{yz}}{l_{ij}} \\ \frac{\partial_{zx}}{l_{ij}} & \frac{\partial_{zy}}{l_{ij}} & \frac{\partial_{zz}}{l_{ij}} \end{bmatrix}$$

Hessiana


$$l_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2 + (z_i - z_c)^2}$$

Distância entre o i-ésimo ponto e a j-ésima fonte equivalente

Modelagem direta

A **anomalia de campo total predita** no i -ésimo ponto de observação gerada por uma **fonte equivalente** é dada por:


$$\Delta T_i^p = \gamma_m \hat{\mathbf{F}}_0^T \mathbf{M}_{ij} \mathbf{m} p_j$$



$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_m \end{bmatrix}$$

O vetor de parâmetros

A inversão dos dados



Queremos estimar uma **distribuição de momentos** que minimize a distância entre os **dados observados** e os **dados preditos** gerados pela camada!

$$\Gamma(\mathbf{p}) = \varphi(\mathbf{p}) + \mu\theta(\mathbf{p})$$


Função objetivo

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{I}) \mathbf{p}^\# = \mathbf{G}^T \Delta \mathbf{T}^o$$

Estimador de mínimos quadrados
(Norma mínima)

$$(\mathbf{G}^T \mathbf{G} + \mu \mathbf{R}^T \mathbf{R}) \mathbf{p}^\# = \mathbf{G}^T \Delta \mathbf{T}^o$$

Estimador de mínimos quadrados
(Suavidade)



Referências Bibliográficas

Aster, R. C., Thurber C. H. & Borchers, B., 2018, Parameter estimation and inverse problems. Third Edition. Academic Press

Blakely, R. J., 1996, Potential theory in gravity and magnetic applications: Cambridge University Press.

Dampney, C. N. G., 1969, The equivalent source technique: Geophysics, 34, 39–53, doi: 10.1190/1.1439996.

Leão, J. W. D., and J. B. C. Silva, 1989, Discrete linear transformations of potential field data: Geophysics, 54, 497–507, doi: 10.1190/1.1442676.

Oliveira, V. C., Jr., V. C. F. Barbosa, and L. Uieda, 2013, Polynomial equivalent layer: Geophysics, 78, no. 1, G1–G13, doi: 10.1190/geo2012-0196.1.

Reis, A. L. A. Reis, Oliveira Jr, V. C. , and Barbosa, V. C. F., (2020). Generalized positivity constraint on magnetic equivalent layers. Geophysics, 85(6), 1-45.

Até breve!