



# Formulação matemática de um problema inverso não-linear

Prof. André L. A. dos Reis

# Objetivos da aula

- \* A formulação de um problema inverso não linear
- \* Métodos por gradiente:
  - Steepest descent
  - Newton
  - Gauss-Newton
  - Levenberg-Marquardt
- \* Diferença entre os métodos

# Formulação de um problema inverso não-linear

**Modelagem direta:** *sintoniza manualmente* o conjunto de parâmetros e compara com os dados observados

**Dados preditos:** dados gerados por um conjunto de parâmetros que descrevem o nosso modelo, que nos traz a relação física e matemática do problema

**Dados observados:** medições realizadas na superfície da Terra

$$\mathbf{d}^p = \mathbf{f}(\mathbf{p})$$

Dados preditos

$$\mathbf{d}^o$$

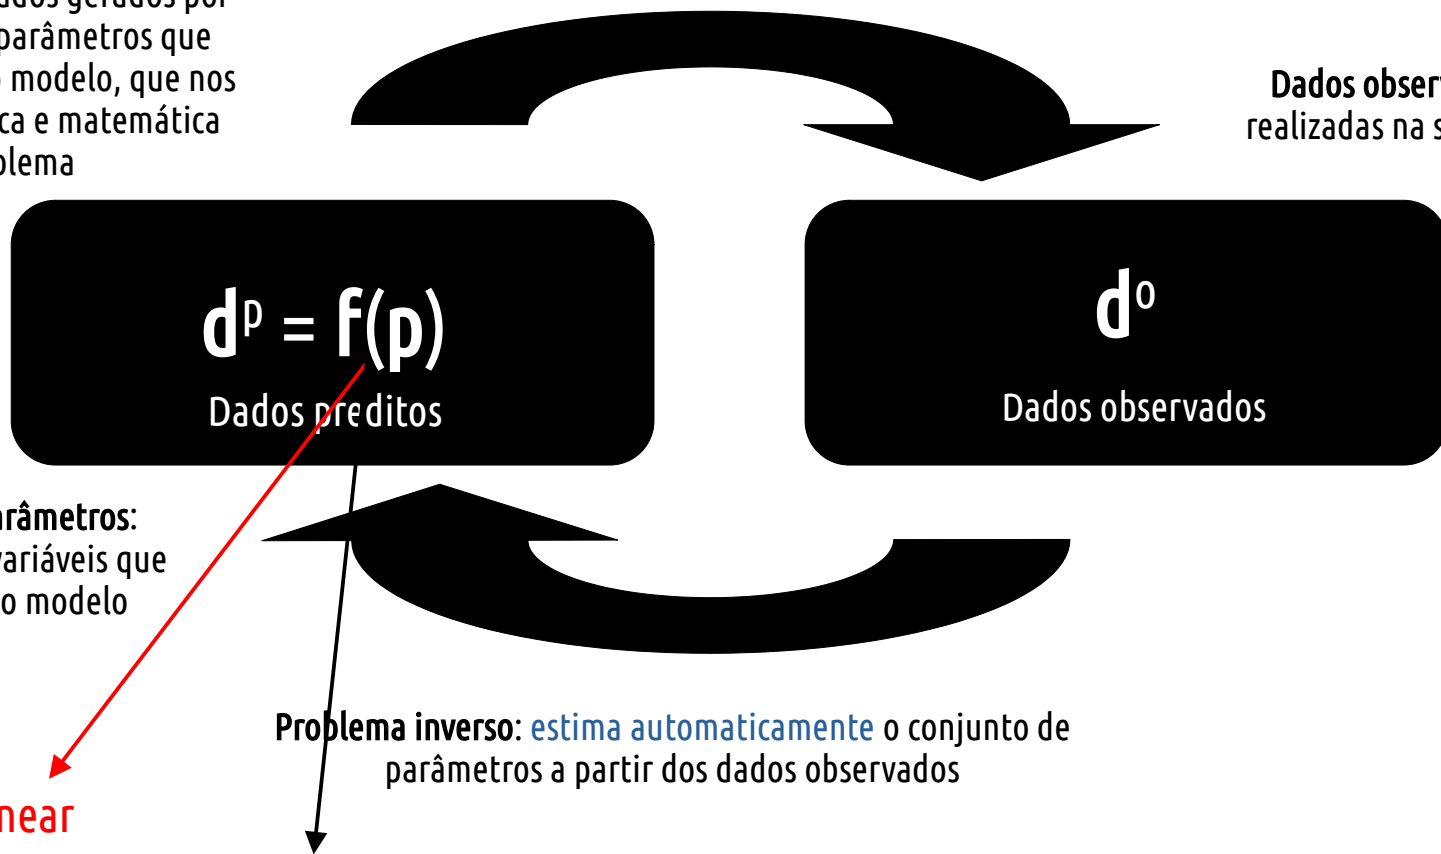
Dados observados

**Vetor de parâmetros:** conjunto de variáveis que descrevem o modelo

Linear

**Problema inverso:** *estima automaticamente* o conjunto de parâmetros a partir dos dados observados

Não-linear



**Modelagem direta:** *sintoniza manualmente* o conjunto de parâmetros e compara com os dados observados

**Dados preditos:** dados gerados por um conjunto de parâmetros que descrevem o nosso modelo, que nos traz a relação física e matemática do problema

**Dados observados:** medições realizadas na superfície da Terra

$$\mathbf{d}^p = \mathbf{f}(\mathbf{p})$$

Dados preditos

$$\mathbf{d}^o$$


Dados observados

**Vetor de parâmetros:** conjunto de variáveis que descrevem o modelo

**Problema inverso:** *estima automaticamente* o conjunto de parâmetros a partir dos dados observados

Linear

Não-linear



## Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

## Problema linear

$$\mathbf{d}^p = \mathbf{G}\mathbf{p}$$

$$(\mathbf{G}^T \mathbf{G})\mathbf{p}^\dagger = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

??????

# Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

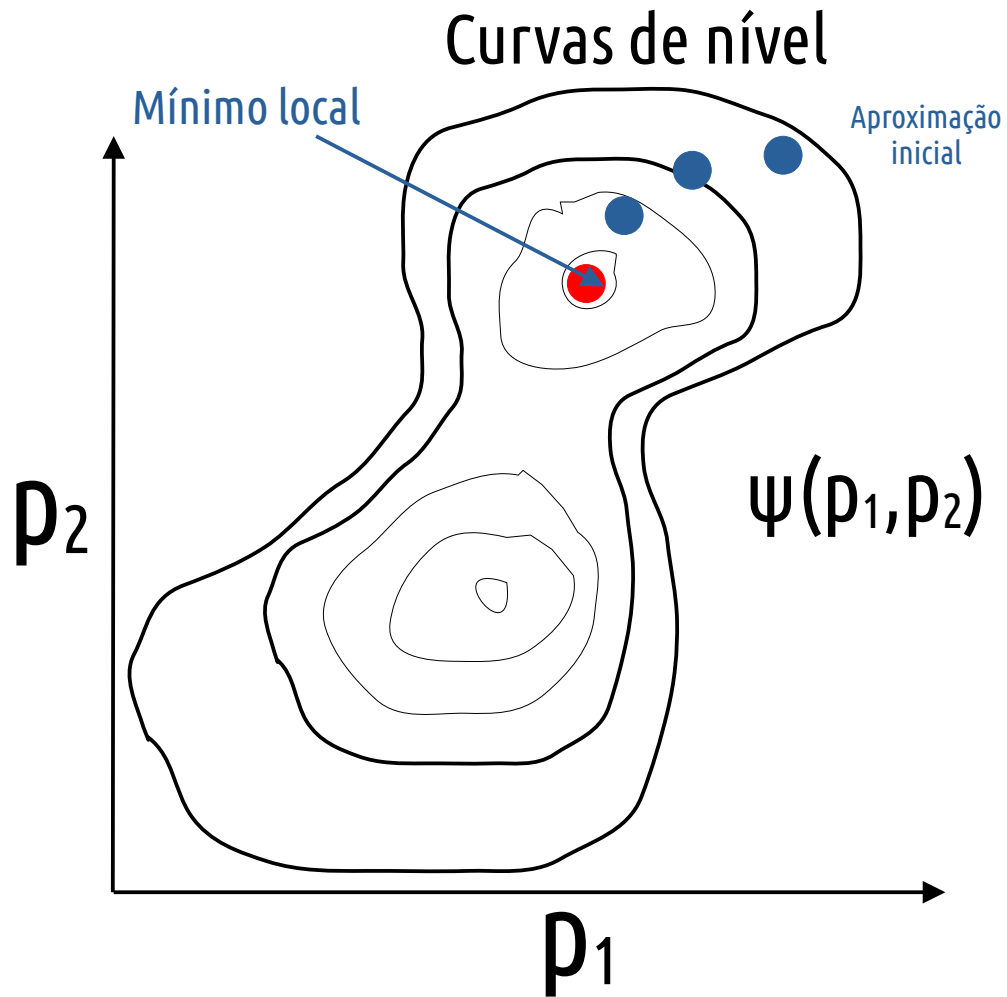
Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste



# Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$


Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste





# Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$


Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste



# Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

Vetor de dados observados

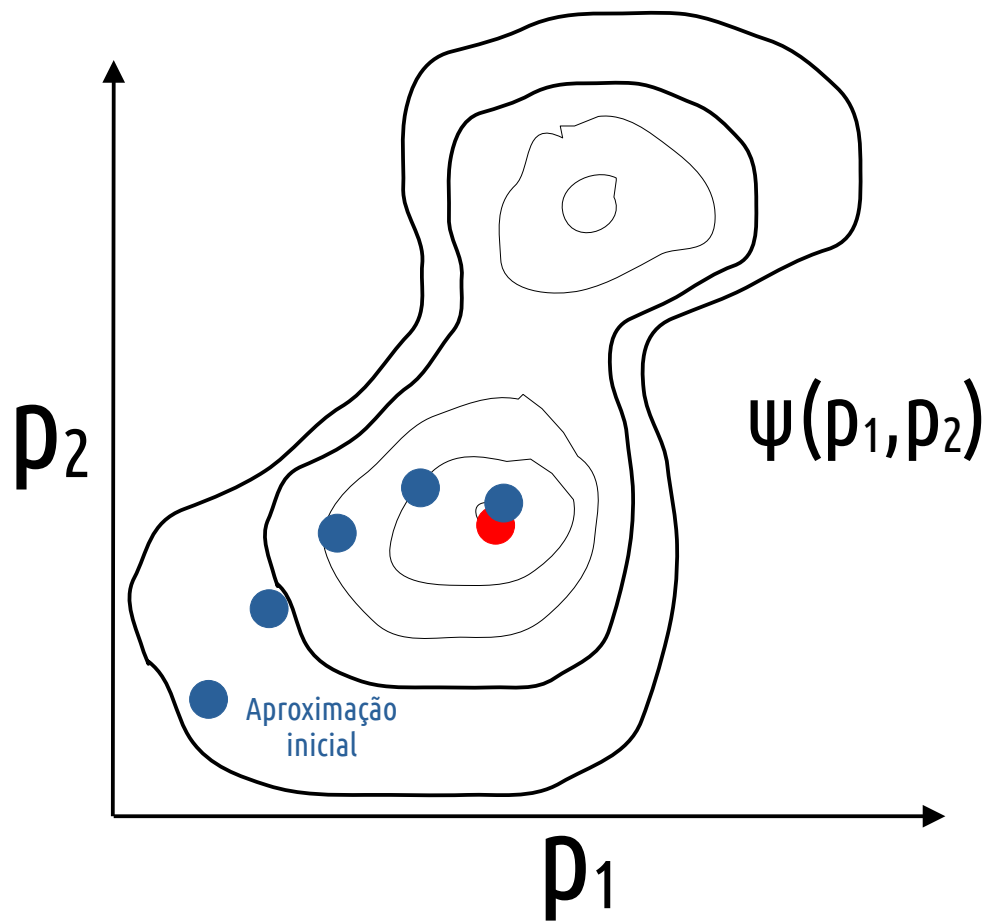
$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

Curvas de nível



# Introdução ao problema não-linear

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

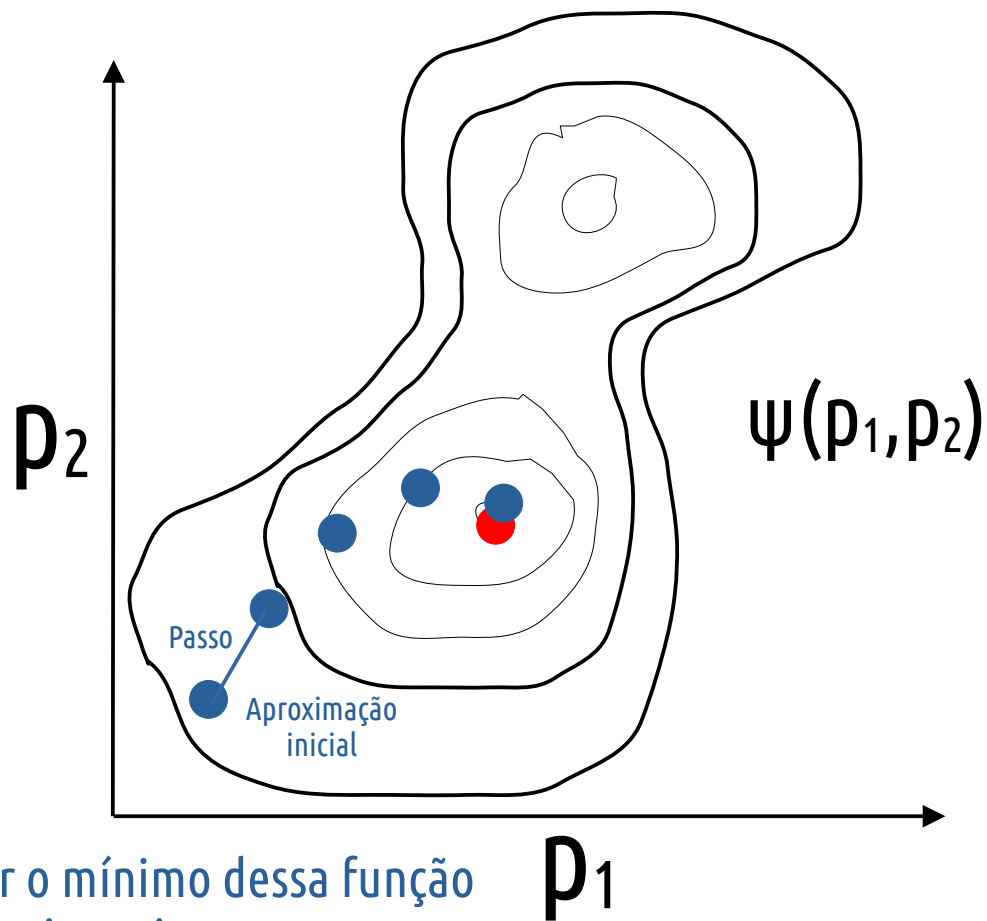
O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

Achar o mínimo dessa função  
iterativamente

Curvas de nível




# Introdução ao problema não-linear

Existem dois tipos de métodos que minimizam estas funções:

**Métodos por gradiente**  
(Determinísticos)

**Métodos Heurísticos**




# Introdução ao problema não-linear

## Métodos por gradiente :

- Steepest descent
- Newton
- Gauss-Newton
- Levenberg-Marquardt

## Métodos Heurísticos :

- Simulated Annealing
- Ant Colony
- Algoritmo Genético



## Métodos por gradiente

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{f}(\mathbf{p})\|_2^2$$

Expandindo a função de ajuste até segunda ordem, teremos:

$$\psi(\mathbf{p}_0 + \Delta\mathbf{p}) \approx \psi(\mathbf{p}_0) + \mathbf{J}(\mathbf{p}_0)\Delta\mathbf{p} + \frac{1}{2}\Delta\mathbf{p}^T \mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Resolveremos este sistema de equações

# Métodos por gradiente

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

## Problema linear

$$\mathbf{d}^p = \mathbf{G}\mathbf{p}$$

$$(\mathbf{G}^T \mathbf{G})\mathbf{p}^\dagger = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

# Métodos por gradiente

$$\mathbf{p} = \begin{bmatrix} p_1 \\ \vdots \\ p_M \end{bmatrix}$$

Vetor de parâmetros

$$\mathbf{d}^p = \begin{bmatrix} d_1^p \\ \vdots \\ d_N^p \end{bmatrix}$$

Vetor de dados preditos

$$\mathbf{d}^o = \begin{bmatrix} d_1^o \\ \vdots \\ d_N^o \end{bmatrix}$$

Vetor de dados observados

$$\nabla \psi(\mathbf{p}) = \mathbf{0}$$

O gradiente da função  
de ajuste

$$\psi(\mathbf{p}) = \|\mathbf{d}^o - \mathbf{d}^p\|_2^2$$

Função de ajuste

## Problema linear

$$\mathbf{d}^p = \mathbf{G}\mathbf{p}$$

$$(\mathbf{G}^T \mathbf{G})\mathbf{p}^\dagger = \mathbf{G}^T \mathbf{d}^o$$

Estimador de mínimos quadrados

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações



# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G} \mathbf{p}$$

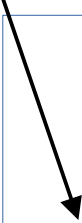
$$\mathbf{H}(\mathbf{p}_0) \Delta \mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$


$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Steepest Descent :  $1/\eta$

Newton :  $\mathbf{H}(\mathbf{p}_0)$

Gauss-Newton :  $\mathbf{J}^T(\mathbf{p}_0)\mathbf{J}(\mathbf{p}_0)$

Levenberg-Marquardt :  $\mathbf{J}^T(\mathbf{p}_0)\mathbf{J}(\mathbf{p}_0) + \lambda\mathbf{I}$

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Vamos às contas!

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Método	Convergência
Steepest Descent	0
Levenberg-Marquardt	1
Gauss-Newton	2
Newton	3

Lenta = 0

Rápida = 3

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Método	Chute inicial
Steepest Descent	Pode ser longe
Levenberg-Marquardt	Pode ser longe
Gauss-Newton	Deve ser próxima
Newton	Deve ser próxima

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Método	Passo
Steepest Descent	Depende de um parâmetro e do gradiente
Levenberg-Marquardt	Depende do gradiente, da Hessiana e de um parâmetro
Gauss-Newton	Depende do gradiente e da Hessiana
Newton	Depende do gradiente e da Hessiana

# Diferença entre os métodos

## Problema não-linear

$$\mathbf{d}^p \neq \mathbf{G}\mathbf{p}$$

$$\mathbf{H}(\mathbf{p}_0)\Delta\mathbf{p} = -\mathbf{J}(\mathbf{p}_0)$$

Sistema de equações

Método	Custo computacional
Steepest Descent	0
Levenberg-Marquardt	2
Gauss-Newton	1
Newton	3

Baixo = 0

Alto = 3

Como regularizar um problema inverso não-linear? E os exemplos?



**Até breve!**